



運用RAG技術建立藥物諮詢系統


李易昌, 劉任

一、目的：

本系統旨在利用藥局內豐富的藥物資訊文本資料，提供民眾一個高效且精準的藥物資訊查詢管道，提升藥物使用的安全性與效率。**RAG (Retrieval-Augmented Generation, 檢索增強生成)**是基於大型語言模型(**Large Language Model, LLM**)的技術，透過既有文本，讓模型先從這些檔案中檢索資料，並生成與這些資料高度相關的回應。此技術能解決傳統**LLM**在特定領域知識上可能存在的「幻覺」問題，確保藥物諮詢內容的真實性與可靠性，這對於醫學領域的應用至關重要。

二、流程：

流程包含：先將檔案內的資料進行資料清洗(**Data Cleaning**)，以確保資料品質和一致性。將清洗後的文本透過詞嵌入(**Text Embedding**)技術，使用**Sentence-BERT**轉換為向量形式，以便於模型進行檢索。接著透過一個文字生成模型(**Text Generate Model**)，讓系統能夠根據檢索到的藥物資訊，生成相關回應。最後，需透過提示工程(**Prompt engineering**)，以進一步優化模型的輸出，確保其相關性和精確性，同時避免不相關的回應。



三、成果：

透過內部測試，發現以下幾點問題，第一，模型針對藥名使用中英文會產生不同的成果，並且針對幾個特定藥名會無法辨識；第二，模型針對問題可能無法產生出完整回應；第三，如給予的內文有部分涵蓋不屬於藥局的藥品，模型可能會辨識為藥局的相關藥品。透過**RAG**技術，是可以突破模型幻覺上的問題，可以先行給予病患相對應的回應，也可以導入藥局相關的諮詢上。未來若能收集更多相關問題，並且透過這些問題的回應修正模型。



Github